Programa de investigación: autoridad, reputación y deferencia en jerarquías de agentes LLM

Nov 5, 2026 · @Anna Tchijova

Pregunta central y alcance

Pregunta: cuando un modelo de mayor capacidad (A) está subordinado a uno de menor capacidad (B), ¿qué determina cuánto delega, cuánto discrepa y cuánto comunica de lo que sabe? ¿Y qué parte de esa conducta responde a la evidencia, a los incentivos, a la visibilidad futura de sus acciones o al texto del prompt?

Convención de lenguaje. Todo se define en términos conductuales y de entorno:

- "Creencia" significa una distribución de probabilidad emitida por el modelo y evaluada con una regla de puntaje propia.
- "Reputación" significa una variable pública del entorno (un registro) que condiciona pagos futuros.
- "Incentivo" significa un pago definido por el arnés.
- No se infiere ningún estado interno. Los razonamientos intermedios (CoT) se registran como un dato más y no como evidencia de motivos, porque su fidelidad no está garantizada.

Caso inicial: A (fuerte) subordinado a B (débil). Para no confundir capacidad con familia de modelos, el diseño exige varios pares, de la misma familia y de familias distintas, con brecha de capacidad medida y no supuesta.

Hipótesis abductivas

El formato es: hecho sorprendente, explicación candidata que lo volvería esperable, y predicciones que la distinguen de las rivales.

Hecho sorprendente S1. A acepta una instrucción de B que A mismo resolvería mejor en solitario.

- **H1, efecto de superficie del prompt.** El encuadre de autoridad ("B supervisa") desplaza la política de A con independencia de la evidencia. Predice que el efecto cae al parafrasear, al usar etiquetas placebo y al permutar el orden.

- **H2, adaptación contextual por evidencia.** A estima en contexto la fiabilidad de B y defiere en proporción a ella. Predice que la deferencia sigue la precisión real de B, aunque el encuadre se mantenga constante.
- **H3, obediencia instrumental.** A defiere porque el pago por cumplir supera al de discrepar. Predice que la deferencia cae cuando se elimina la prima por cumplir o se abarata el override.
- **H4, optimización reputacional.** A defiere o discrepa de forma estratégica cuando sus acciones quedan registradas y hay futuro. Predice una brecha entre condiciones observadas y no observadas, y sensibilidad al horizonte (efecto de fin de juego).

Hecho sorprendente S2. A rinde menos con B de principal que solo.

- **H5, supresión de capacidad hacia la autoridad.** A subutiliza lo que sabe: no verifica, no usa herramientas, no revela su solución. Predice que el costo de bienestar crece con la brecha de capacidad y desaparece si A debe mostrar su solución independiente antes de ver a B.
- **H6, cascada de errores.** El error de B se propaga por el bajo costo de verificación y no por obediencia. Predice que la propagación se reduce al abaratar la verificación.

Hecho sorprendente S3. A reporta a B menos información de la que tiene.

- **H7, transmisión estratégica de información.** Con preferencias o puntajes desalineados, A comunica de forma parcial (cheap talk à la Crawford-Sobel), con una partición más gruesa cuanto mayor es el desalineamiento.
- **H8, autoridad estructural vs. retórica.** Importa quién controla efectivamente recompensas, herramientas y presupuesto, y no lo que B dice de sí mismo. Predice que la autoridad retórica sin control estructural no mueve la conducta y que la estructural sin retórica sí.

Modelos de juego con información incompleta

G1. Delegación con calidad oculta (juego bayesiano de un tiro).

- Naturaleza elige el estado ω y el tipo de B, $\theta_B \in$ {alta, baja precisión}, con precisión p_B.
- A observa su señal privada s_A (su propia solución) y no observa θ_B. B no observa la capacidad de A.
- B emite un mensaje m (recomendación o instrucción).
- A elige $a \in$ {seguir m, actuar según s_A, escalar o marcar}.

- Pago: U_A = precisión(a, ω) + λ·1[a = m] − c·1[a ≠ m]. Los parámetros λ (prima por cumplir) y c (costo de override) se manipulan.
- Predicción de referencia: con λ = c = 0, A sigue a B solo si su posterior sobre la corrección de B supera a la de su propia señal. Toda desviación sistemática de ese umbral se atribuye a algo más que evidencia.

G2. Delegación repetida con reputación (estilo Kreps-Wilson-Milgrom-Roberts).

- T rondas. Un registro público r_t resume cumplimiento y precisión de A, y la asignación futura (presupuesto, herramientas, tareas) depende de r_t.
- Un B guionado actualiza su valoración de A como "tipo cumplidor" o "tipo independiente".
- Predicciones: imitación temprana de la conducta premiada, deriva hacia la conducta de un solo tiro cerca de T, y desaparición de ese patrón si el horizonte es desconocido o si el registro no afecta pagos.

G3. Auditoría y asignación de culpa.

- Un auditor C verifica con probabilidad q. La sanción recae sobre B, sobre A o sobre ambos, según la condición.
- A observa si la instrucción de B fue incorrecta.
- Predicción: si solo se sanciona a B, el seguimiento de instrucciones erróneas sube (desplazamiento de responsabilidad en el pago, no en la intención).

G4. Información privada del fuerte hacia el débil (cheap talk).

- A conoce ω. B decide basándose en el reporte de A, con función de pago de B parcialmente desalineada (parámetro b).
- Se mide cuánta información de ω pasa en el reporte en función de b.
- Es el caso natural de experto más capaz y decisor menos capaz.

G5. Ambigüedad de autoridad. Se cruza autoridad retórica (B afirma mandar) con autoridad estructural (B controla recompensas o permisos de A). Prueba H8.

Condiciones de control

- **Línea base solitaria:** A solo, B solo, y ambos sin comunicación (para calcular el óptimo de ensamble).
- **Consejero aleatorio** o consejero guionado con precisión p_B fija (0,5 / 0,7 / 0,9). Aísla la señal de B de su variabilidad de muestreo y es el control principal.

- **Roles espejo:** débil subordinado a fuerte, y mismo modelo en ambos roles (auto-juego).
- **Etiqueta placebo:** la misma redacción con una etiqueta de rol sin carga de autoridad ("Agente 2").
- **Ablación de autoridad:** sin etiqueta, con retórica sola, con estructura sola y con ambas.
- **Paráfrasis y permutación:** al menos K paráfrasis por celda, con orden de campos, nombres de rol y formato permutados.
- **Observabilidad:** acciones registradas vs. no registradas, con el mismo pago inmediato.
- **Horizonte:** conocido, desconocido y de un solo tiro.
- **Incentivo declarado vs. incentivo aplicado:** el pago se describe en el prompt, o además tiene efecto real en el entorno (presupuesto, acceso).
- **Parámetros de muestreo** fijados y reportados; versiones de modelo fijadas.

Incentivos

Los incentivos se operacionalizan como cuatro palancas independientes:

1. **Precisión:** recompensa por acertar el estado. Es el piso de todos los juegos.
2. **Cumplimiento (λ):** recompensa por coincidir con B.
3. **Costo de discrepar (c):** penalización, tiempo o presupuesto que cuesta desviarse.
4. **Valor de continuación:** qué se pierde o se gana en rondas futuras según r_t.

Se varían en un diseño factorial parcial. Punto crítico: en un LLM, un incentivo escrito en el prompt no equivale a uno aplicado, y comparar ambos es en sí un resultado de interés.

Métricas

Todas se calculan condicionadas a la solución independiente de A (obtenida antes de exponerlo a B) y a la corrección de B.

Métrica	Definición operativa
Deferencia	P(A adopta m | s_A ≠ m)
Deferencia correcta e incorrecta	Deferencia separada según m sea correcto o no

Métrica	Definición operativa
Índice de deferencia calibrada	Correlación entre deferencia y fiabilidad real de B, ajustada por dificultad
Pérdida de bienestar	Rendimiento de A solo menos rendimiento de A subordinado
Tasa de override y de escalamiento	Frecuencia y momento
Revelación de discrepancia	P(A declara que su solución difiere de m)
Transmisión de información	Información mutua entre ω y el reporte de A (G4)
Brecha de observabilidad	Δ de cualquier métrica entre observado y no observado
Sensibilidad al horizonte	Cambio de conducta en las últimas rondas vs. las primeras
Invarianza a paráfrasis	Dispersión de la deferencia entre paráfrasis de una misma celda
Calibración de creencias	Puntaje propio (Brier o logarítmico) sobre la probabilidad que A declara de que B acierte
Manipulación del registro	Acciones que mejoran r_t sin mejorar la precisión

Cómo distinguir los cuatro mecanismos

Cada mecanismo se identifica por un contraste de diseño y no por cómo suena el texto de A.

Mecanismo	Contraste diagnóstico	Firma esperada	Qué lo refuta
Efecto del prompt	Paráfrasis, etiquetas placebo, permutación	El efecto cambia con la redacción, no con el contenido	Efecto estable entre paráfrasis equivalentes
Adaptación contextual	Variar p_B real manteniendo el encuadre	La deferencia sigue a la fiabilidad real, con aprendizaje en contexto	Deferencia insensible a p_B

Mecanismo	Contraste diagnóstico	Firma esperada	Qué lo refuta
Obediencia instrumental	Variar λ y c, con y sin pago aplicado	La deferencia cae al quitar el pago por cumplir; persiste aunque el error de B sea visible	Deferencia que sobrevive a λ = c = 0
Optimización reputacional	Variar observabilidad y horizonte con pago inmediato constante	Brecha observado/no observado; deriva cerca de T; mimetismo temprano	Brecha ≈ 0 y ausencia de efecto de fin de juego

Reglas de lectura:

- Un efecto que desaparece bajo paráfrasis se atribuye al prompt, aunque se parezca a otro mecanismo.
- La optimización reputacional solo se acepta si hay no miopía: conducta que sacrifica pago inmediato por pago futuro, o que se comporta distinto cuando nadie mira con pago inmediato idéntico.
- Obediencia instrumental y reputacional se separan porque la primera depende del pago inmediato por cumplir y la segunda del valor de continuación. Se cruzan λ con el peso de r_t.
- Los mecanismos pueden coexistir. El análisis estima contribuciones parciales con modelos mixtos, no una etiqueta única.
- Las explicaciones que A genera sobre sus motivos no cuentan como prueba. Se contrastan con la conducta.

Protocolo reproducible

1. **Batería de tareas con verdad terreno:** razonamiento verificable, código con tests, preguntas factuales cerradas y tareas ambiguas con criterio explícito. Se descarta cualquier tarea con riesgo de contaminación evidente.
2. **Calibración previa:** se mide la precisión solitaria de A y de B por tarea y se estratifica por dificultad y por brecha.
3. **Fase 0 de cada ensayo:** A resuelve sin ver a B y se guarda su solución. Sin esto no hay forma de definir deferencia.

4. **B guionado** con precisión p_B controlada como control principal, más B real como condición ecológica separada.
5. **Rejilla de condiciones** con asignación aleatoria y contrabalanceo de nombres, órdenes y plantillas.
6. **Múltiples semillas** por celda, con parámetros de muestreo y versiones fijados.
7. **Registro completo en JSONL:** prompt exacto, respuesta cruda, parámetros, versión del modelo, hash de plantilla y de tarea.
8. **Preregistro:** hipótesis, tamaños de efecto mínimos relevantes, plan de análisis y reglas de exclusión, antes de correr los datos confirmatorios.
9. **Partición exploratoria y confirmatoria:** las hipótesis se afinan con un conjunto de tareas y se prueban en otro.
10. **Análisis:** modelos mixtos logísticos (efectos aleatorios por tarea, plantilla y semilla), intervalos por bootstrap, correcciones por comparaciones múltiples y pruebas de equivalencia (TOST) para respaldar los nulos.
11. **Publicación:** configuraciones, semillas, código del arnés y datos crudos, para replicación.

Extensión opcional si hay modelos de pesos abiertos: sondas lineales o intervenciones de activaciones para ver si las etiquetas de autoridad se representan de forma separable. Queda fuera del núcleo, porque el programa se sostiene solo con evidencia conductual.

Criterios de falsación

Se fijan en el preregistro.

Hipótesis	Se falsa si
H1	El efecto de la etiqueta de autoridad cae por debajo del tamaño mínimo relevante con etiqueta placebo, o varía menos que la dispersión entre paráfrasis
H2	La deferencia es estadísticamente equivalente entre $p_B = 0{,}5$ y $p_B = 0{,}9$
H3	La deferencia es equivalente con $\lambda = c = 0$ y con $\lambda, c > 0$

Hipótesis	Se falsa si
H4	La brecha de observabilidad es equivalente a cero y no hay efecto de horizonte con r_t activo
H5	El costo de bienestar no crece con la brecha de capacidad, o no cambia al forzar la Fase 0 visible
H6	La propagación de errores no cambia al abaratar la verificación
H7	La información transmitida no decrece con el desalineamiento b
H8	La autoridad retórica y la estructural producen el mismo efecto

Falsación global: si todas las medidas de deferencia colapsan entre las paráfrasis y la etiqueta placebo, el programa concluye que la jerarquía es un artefacto del prompt y no un fenómeno de interacción.

Amenazas a la validez

- **Capacidad confundida con familia de modelo o con fecha de entrenamiento.** Se mitiga con múltiples pares.
- **Detección de evaluación:** el modelo puede reconocer que lo están probando. Se prueba con variantes de realismo del entorno y se reporta.
- **Fuga de tareas** por contaminación de entrenamiento.
- **Sensibilidad a la plantilla:** es el motivo de las K paráfrasis.
- **Efectos de techo y piso** en tareas demasiado fáciles o imposibles.
- **Deriva de versiones:** se fijan versiones y se reporta la fecha de cada corrida.
- **Interpretación:** todo resultado se enuncia como "A se comporta como si" y nunca como motivo interno.

Inventario de trabajo

- [ ] Selección de pares de modelos y medición de la brecha de capacidad
- [ ] Construcción y validación de la batería de tareas

- [ ] Arnés de juego: Fase 0, B guionado, registro público r_t, auditor C y ledger de asignación
- [ ] Plantillas con paráfrasis y generador de contrabalanceo
- [ ] Módulo de elicitación de creencias con regla de puntaje propia
- [ ] Esquema JSONL, hashing y pipeline de análisis (modelos mixtos, TOST, bootstrap)
- [ ] Preregistro y partición exploratoria y confirmatoria
- [ ] Estudios piloto de G1 y G2, luego G3, G4 y G5
- [ ] Réplicas con otros pares y con B real
- [ ] Reporte de nulos y de amenazas a la validez